

Instructions des projets - MLOps et Déploiement de modèles

DEML - Master Data Engineering et Machine Learning

Date limite (présentation de projets) 4 juillet 2026.

Rendu attendu :

1. Une présentation en classe (en ligne 25min/groupe) avec une démo du travail effectué.
2. Liens d'accès (Application Flask déployée, lien interface MLflow, lien repository Git — vous pouvez le garder privé en m'ajoutant dessus, yehdiouldanna@gmail.com sur GitHub). Assurez-vous que tout fonctionne au moment de la date limite de soumission.
3. Un Mini rapport de 1 à 5 pages (max), Votre rapport doit contenir, les liens précédemment mentionnés. Une Présentation du problème ML et du data-set (ne pas dépasser une page sur ça). Et l'Architecture technique mise en place (schéma + explications).

1. Repository GitHub et Collaboration

- Créez un repository GitHub pour votre projet.
- L'historique Git fera partie de votre évaluation :
 - Chaque membre du groupe doit créer au minimum une branche personnelle contenant ses contributions. (Minimum 3 commits par membre).
 - Votre repository doit présenter un arbre Git clair avec plusieurs merges (pas un simple dépôt linéaire).
- Soignez vos messages de commit et la structuration des branches.

2. Tracking des Expériences avec MLflow (sur AWS EC2)

- Créez un serveur MLflow Tracking déployé sur une instance AWS EC2.
- Vous pouvez réutiliser une machine créée pendant le cours. Ne multipliez pas les instances : une seule machine EC2 suffira pour tout le groupe.
- Toutes les expériences (entraînement, évaluation, tests) doivent être loguées dans MLflow dès le départ afin d'obtenir un historique complet et cohérent.

3. Stockage des Données avec Amazon S3

- Créez un bucket S3 qui servira de répertoire partagé pour stocker :
 - Les données brutes (raw data)
 - Les données prétraitées
 - Les modèles sauvegardés et tout fichier versionné avec DVC

4. Préparation du Pipeline Machine Learning

Implémentez les scripts suivants dans votre projet :

1. Script de prétraitement des données
2. Script d'entraînement du modèle
3. Script d'évaluation du modèle
 - Intégrez MLflow dans ces scripts dès le début pour enregistrer :
 - Les hyperparamètres
 - Les métriques de performance
 - Les modèles produits
 - Enregistrer (registrar) uniquement les meilleurs modèles

5. Pipeline Reproducible avec DVC

- Créez un pipeline complet avec DVC pour garantir la reproductibilité :
 - Versionnez les données, les modèles, les scripts d'entraînement et d'évaluation.
 - Configurez S3 comme entrepôt distant pour DVC (remote storage).
- Créez au moins deux versions différentes des données et assurez-vous de pouvoir passer de l'une à l'autre avec DVC.

6. Déploiement : Interface Web avec Flask ou autre

- Créez une application web simple avec Flask permettant d'interagir avec votre modèle :
 - L'application doit contenir un formulaire pour saisir les entrées nécessaires à la prédiction.
 - Elle doit appeler le modèle le plus récent enregistré dans le serveur MLflow (via le Model Registry) pour effectuer la prédiction.
 - Elle doit afficher le résultat de la prédiction à l'utilisateur dans l'interface.
 - Pour une meilleure flexibilité, déployez l'application Flask sur une seconde machine EC2.
 - NB : Flask est juste une option, vous pouvez utiliser d'autres frameworks.

7. Documentation et Valorisation de votre Travail

- Votre repository GitHub doit contenir un fichier README clair et bien structuré comprenant :
 - Une présentation du problème traité
 - La description de l'architecture technique mise en place
 - Les instructions détaillées pour reproduire l'environnement et relancer le projet
 - Des captures d'écran illustrant le suivi des expériences (MLflow), la gestion des données (DVC) et l'interface web (Flask)
 - Toute information que vous jugez utile pour mettre en valeur la qualité de votre travail.